

AI Werewolf

多智能体狼人杀项目汇报

对战 Play • 复盘 Evaluate • 进化 Evolve

- 严格信息隔离下的多 Agent 博弈系统
- 完整对局引擎 + 观战 UI + 真人 / AI 混战入口
- Track B 决策复盘评价, Track C 策略知识回流

Play - Evaluate - Evolve 闭环

一局游戏产生可审计决策, 赛后评分产生复盘, 复盘经验进入知识库并回流到下一局。



图表说明：闭环是系统设计主线；占位或实验数值不在本图中表达。

2026-06-08

wxhfy / 付一涵

从产品定位、系统架构、核心创新到验收证据

01 项目定位

为什么狼人杀适合作为信息不对称多智能体研究平台

02 系统架构

前后端实时系统、规则引擎、Agent 决策与数据库证据链

03 核心创新

信息隔离、CognitiveAgent、Track B 复盘、Track C 自进化

04 验收与边界

自动化测试、端到端 smoke、风险项与下一步计划

一句话结论：项目已形成可演示、可复盘、可积累策略知识的 AI 狼人杀闭环系统。

研究问题

在信息不对称、阵营对抗和自然语言交流同时存在的环境里，如何让 Agent 既遵守规则，又具备角色化推理、社交判断、复盘学习能力？

完整对局

15+ 细分阶段，夜晚技能、白天发言、投票、胜负判定

严格隔离

GameState 与 PlayerView 分离，Agent 只看到身份允许的信息

角色化 Agent

MBTI 人格 + Role 身份 + Strategy 知识三层架构


可复盘进化

每步决策可审计、可解释，并沉淀为下一局策略

两条主线



系统闭环：对局执行 → 赛后复盘 → 经验抽取 → 下一局策略回流



Agent 认知层：人格决定风格，身份决定规则边界，策略决定如何赢

系统总体架构

前端实时观战、后端规则引擎、Agent 决策、B/C 评测进化闭环

Architecture

架构要点

- FastAPI + WebSocket 承担房间、快照和实时事件推送
- WerewolfGame 是唯一规则主控，Agent 只提交 Decision
- PostgreSQL 保存事件、快照、决策、复盘和知识
- Track B/C 在赛后消费证据链，再回流到 StrategyRetriever

20+

核心 ORM / 证据表

games / events / decisions / reviews / knowledge

7

主要页面路由

大厅、对局、Human、复盘、看板、Persona

AI 狼人杀多智能体对战与自进化系统架构

Play 局内对战 → Evaluate 赛后评分 → Evolve 知识回流；所有真实数据经 PostgreSQL 证据链追溯。




图表说明：本图为报告展示图；模块名称来自当前代码与项目文档，非实验结论。

单局对局流程

夜晚技能、白天发言投票、胜负判定与赛后处理

单局对局端到端流程

从创建房间到终局复盘，每个 Agent 行动都经过信息隔离、工具决策、引擎结算和证据链记录。



图表说明：本图描述单局执行路径；真实耗时、决策数和产出量需由运行日志或数据库统计补充。

阶段流转

阶段	关键动作	主控
夜晚	守卫 / 狼刀 / 女巫 / 预言家	引擎结算
白天	发言 / 警长 / 投票 / 遗言	阶段机调度
终局	胜负判定 / 复盘 / 知识抽取	B/C 后处理

- Agent 不直接修改 GameState，所有行动先过合法性校验
- 夜晚并行动作在结算阶段统一处理，避免先后执行悖论
- 终局后自动形成可回放、可审计、可抽取知识的证据链

核心模块清单

从引擎到前端的可交付模块

Modules

核心功能模块图

九个分层模块共同支撑“完整对局、可审计复盘、策略知识回流”的产品能力。



图表说明：该图强调模块职责和上下游边界；具体代码实现只作为证据来源，不在图中展开。

模块	职责	状态
WerewolfGame	初始化、阶段推进、结算、胜负、事件记录	通过
Visibility	GameState -> PlayerView，信息裁剪	92/92
CognitiveAgent	Observe / Memory / Planner / Tools / LLM	通过
Track B	决策审计、复盘、证据引用	通过
Track C	lesson 抽取、知识生命周期、检索回流	通过
Frontend	大厅、观战、Human、复盘、仪表盘	通过

设计原则：规则由引擎控制，视图由 Visibility 裁剪，Agent 输出意图，所有行为进入审计链。

信息隔离：可信博弈的底座

Visibility

GameState 是真相，PlayerView 是每个 Agent 的合法局部视角

92/92

边界检查

verify_visibility_strict.py

0

公开角色泄漏

demo public role leak=false

3

视图体系

观众 / 上帝 / 玩家




隔离边界

- 村民不可见查验、女巫夜间受害者、狼队沟通
- 狼人只可见狼队队友，不可见神职私有结果
- 预言家只可见自己的查验，女巫只可见自己的药与受害者
- public event 不泄露角色分配或查验结果

CognitiveAgent：角色化决策主体

Observe -> Think -> Act -> Reflect，工具调用 trace 可审计

Agent



三层 Prompt / 认知上下文

层	作用
Persona / MBTI	控制表达风格、认知倾向、风险偏好
Role Identity	定义身份、阵营、技能和胜利条件
Strategy + Tools	注入当前可用策略、反模式和检索结果

收益：角色差异、记忆连续性、社交判断和策略回流都能进入同一条可审计决策链。

Play → Evaluate → Evolve

系统不只跑一局，还能解释一局、积累一局

Closed Loop

Play - Evaluate - Evolve 闭环

一局游戏产生可审计决策，赛后评分产生复盘，复盘经验进入知识库并回流到下一局。



图表说明：闭环是系统设计主线；占位或实验数值不在本图中表达。

Play

完整对局执行，写入 GameEvent / Snapshot / AgentDecision

Evaluate

Track B 评价关键决策，生成 ScoredStep 和 PublishedReview

Evolve

Track C 抽取 lesson，进入 candidate / active 知识池再被检索

Track B：决策复盘评价

Evaluate

从“谁赢了”推进到“每一步为什么好 / 坏”

三级评价链路



- 明确场景用规则：投票、技能目标、信息泄露、非法行动
- 模糊场景用轻量 LLM：发言有效性、推理质量、局势影响
- 高影响决策可进入复核流程，保留 counterfactual 和证据引用

输出对象



42
passed

B/C 验收专项

test_api /
test_b_full_acceptance /
test_track_c

27/27

strict ScoredStep 覆盖

backend_acceptance 记录

可展示价值

复盘报告不只是文本总结，而是可回链到原始事件、Agent 决策和当时可见信息的证据化报告。


Track C：知识抽取与安全回流

Evolve

把复盘结论沉淀为下一局可检索策略

Track B 评分与 Track C 知识回流流程

胜负只能说明结果，Track B/C 负责解释过程、沉淀经验，并控制新知识进入策略池的风险。



图表说明：该图是流程说明，Track B Tier 触发比例和 Track C 晋级率需通过后续实验统计。

知识生命周期



- 新 lesson 默认进入 candidate，避免直接污染 active 策略池
- 检索侧使用 confidence / visibility / privacy / applicability 四重过滤
- 保留 source_game / source_event / source_item，知识可追溯
- Track C 只注入 Strategy 层，不污染身份规则和人格风格

401

当前 active

DB 快照

3856

当前 candidate

DB 快照

127k

usage feedback

DB 快照

产品化界面

Frontend

Next.js 观战 UI、Human 模式、复盘与评测仪表盘

/

大厅 / 创建房间

已纳入 build / UI smoke 验证

/room/[id]/human

真人玩家操作

已纳入 build / UI smoke 验证

/eval/dashboard

评测仪表盘

已纳入 build / UI smoke 验证

/room/[id]/play

AI 对局观战

已纳入 build / UI smoke 验证

/games/[id]/report

单局复盘报告

已纳入 build / UI smoke 验证

/personas

Persona 库

已纳入 build / UI smoke 验证

UI smoke 覆盖：对局到 GAME_END、复盘 iframe、HTML 复盘资产、中英文切换、AI/Human 房间流程。

自动化验收结果

Acceptance

当前工作区本地可复现验证， fake LLM provider ，日期 2026-06-08

449 passed

pytest tests/

27 skipped, 26 warnings

passed

E2E smoke

scripts/e2e_smoke.py

92 / 0

Visibility strict

92 passed, 0 failed

GAME_END

Demo game

10 players, 157 events

lint + build

Frontend

UI smoke passed

42 passed

Track B/C

关键链路专项

维度	结论	证据
对局引擎	通过	backend.run_demo 到 GAME_END
信息隔离	通过	92 项检查， public role leak=false
后端 API	通过	rooms / games / snapshot / health smoke
前端流程	通过	build + browser smoke
复盘与进化	通过	报告导出、 B->C 、知识回流

本轮修复与风险边界

Risks

验收中发现的问题已收敛，同时保留真实 LLM 长跑等补验项

已修复

- 恢复 Track B speech semantic audit 与 speech act classifier 报告
- 补齐 StrategyKnowledgeDocData experiment_id 传递
- 修复 AbstractedLesson 到 PostgreSQL 字段映射
- 修复知识 upsert 时间序列化与 UI smoke 断言

风险与补验

- 答辩前建议用真实 provider 跑 7P / 9P / 12P 各 1 局
- Track C 胜率提升仍需 paired seed 在线 A/B 实验
- 并发 WebSocket / 重连压力测试未作为本轮自动化主项
- 数据库历史实验需按 experiment_id / provider / strict 标记过滤

结论边界

当前 PPT 中的验收结论引用的是本地可复现自动化结果；历史数据库快照和占位图表不混写为正式提升结论。

总结与下一步

Summary

从可玩系统到可验证研究平台

当前交付

能玩

完整狼人杀引擎，支持 AI 对局、Human 模式、实时观战

能解释

事件、决策、复盘全链路可追溯

能积累

Track C 将复盘经验转为可检索策略知识

下一步

- 冻结一次真实 LLM + PostgreSQL strict 验收输出
- 补 paired seed 多局 A/B，量化 Track C 对胜率 / 决策分的影响
- 扩展并发观战、断线重连和更多角色规则专项测试
- 将复盘报告与策略卡进一步产品化，形成演示闭环

最终判断：当前项目主体功能达到交付演示与答辩验收要求。